

BioFauna: identificación marina mediterránea por recuperación sobre BioCLIP-2.5 ViT-H congelado

Autor: Gustavo Zafra (Yespi) **Aportación taxonómica:** Xavier Salvador, Miquel Pontes, Manuel Ballesteros

Repositorio: <https://github.com/yespi/biofauna> **Sistema en vivo:** <https://fotofauna.yespi.es> **Esta versión:** 2026-09-14 (corte de producción)

Nombre. El proyecto se llamó YOLOFauna (2024–mediados de 2026); pasó a BioFauna cuando producción se quedó en recuperación BioCLIP, no en detectores YOLO. Origen: [docs/HISTORY.md](#).

Actualización 29-sep-2026 — evaluación de campo ampliada a 76.585 filas, fuga a nivel de observador purgada, segmentación por realm. Dos rondas de minería ampliaron la evaluación de campo de 62.408 a **76.585 filas** (ronda 1: +11.156 filas al 84,8% de acierto; ronda 2: +4.691 filas al 87,8%). Una auditoría a nivel de revisor midió la **fuga por observación/observador**: el 2,17% de las filas (1.595) compartían el id de observación o el observador con la galería de referencia de su propia especie; excluirlas cambia el acierto solo **-0,14 pp**, por lo que la cifra operativa no está inflada de forma material. Acierto final segmentado: **82,34% global** (76.585 filas), marino 80,37%, terrestre 93,37%, aves 92,22%, foránea 82,08%. El campo `realm` (marine / terrestrial / aves / foranea) se añadió al catálogo como **metadato para estadísticas segmentadas — no filtra** la identificación ni la publicación, porque Minka incluye aves y organismos terrestres. **Composición de la cifra (revisión del 29-sep):** el eval original (60.743 filas) da **81,18%**, comparable con versiones anteriores; las 15.842 filas minadas dan 85,5% y 89,9% en las dos rondas, pero en las 1.785 especies con filas de ambos tipos el acierto es equivalente (86,8% minadas frente a 86,1% originales). El aumento global refleja, por tanto, la composición por especies y no un cambio del modelo (que no cambió). Todas las filas minadas pasaron el mismo filtro de fuga (observación, observador, similitud de embedding $\geq 0,98$). **Precisión real de las publicaciones de AutoID** (500 publicaciones históricas, 493 verificables frente a identificaciones posteriores de terceros en Minka): **96,6%** (IC95% 94,5–97,8); por banda de confianza calibrada 85% (0,83–0,85, $n=27$), 93% (0,85–0,90), 95,5% (0,90–0,95), 99% ($\geq 0,95$, $n=252$). **Composición del 82,34%.** Agrupa tres bloques: el conjunto de evaluación original (60.743 filas, **81,18%**, la cifra comparable con todas las versiones anteriores), la ronda 1 de minería (11.154 filas tras la purga, 85,49%) y la ronda 2 (4.688 filas, 89,87%). Dentro de las 1.785 especies con filas en el bloque original y en los minados, el acierto es 86,1% frente a 86,8% (+0,7 pp): a igualdad de especie las filas minadas no son más fáciles, y la subida viene sobre todo de la composición (especies con más pool). **Para comparar con versiones anteriores, usar 81,18%.**

Actualización 1-oct-2026 — kNN en GPU y fallback por recortes para fotos de baja confianza. (1) El perfilado mostró que el 50% del tiempo de `/identify` era la búsqueda FAISS exacta en una CPU de 4 hilos (0,5 s por consulta); los vectores del índice viven ahora en la GPU en fp16 y los vecinos devueltos se re-puntúan en fp32 contra el índice de CPU, así que las similitudes son las exactas (prueba golden: sin diferencias en 40 fotos). Seis identificaciones de una foto pasaron de 4,4 s a 0,97 s. (2) Un fallback por recortes actúa solo cuando la imagen completa no da una identificación publicable (p calibrada por debajo del umbral, o rango superior a especie): se identifican cuatro cuadrantes, un centro con 17% de padding, un recorte por saliencia y un centro al 40%, y se rescata una especie cuando al menos dos pasos coinciden con $p \geq 0,93$ (tres si su género difiere del top-1 de la imagen completa); los empates ($<0,05$) se abstienen. Solo puede añadir publicaciones. En 500 fotos reales aún sin identificar de la cola de AutoID, las

identificaciones publicables pasaron de 35 a 48; en 747 fotos con verdad de terceros, lo añadido acertó en el 85,7% (42/49; cota inferior de Wilson al 95%: 73%). Bajar simplemente el umbral de la imagen completa para añadir el mismo número de fotos da un 83,7% de aciertos, pero solo coinciden 11 de las 49 fotos, así que el fallback recupera fotos distintas. En esos bancos (más difíciles que producción) la precisión global de publicación bajó del 93,9% al 92,7%; la precisión real de los rescates publicados se está midiendo con identificaciones posteriores de terceros. (3) Un modelo de confianza mayor (gradient boosting con 13 señales), ejecutado en modo sombra sobre 726 publicaciones reales, no mejoró al calibrador logístico (AUC 0,820 frente a 0,820; cobertura al 97% de precisión 94,1% frente a 92,8%), por lo que se queda en sombra.

Actualización 28-sep-2026 — higiene de galería, evaluación de campo honesta y rescate zero-shot. Tras el arreglo de la fuga (23-sep) la cifra de conjunto cerrado quedó en 88,11% sobre el conjunto sin fuga; la evaluación **operativa** pasó a una **evaluación de campo** (solo fotos de campo, iNaturalist/Minka research grade, 20–30 fotos por especie, auditada contra fugas antes de fusionar): **62.408 filas → 81,4% especie / 84,9% género**. Higiene de galería en el mismo periodo: **135 slugs sinónimos duplicados fusionados** (autoridad de nombres: **Minka**; si en Minka existen los dos nombres *no* se fusiona; si no, la sinonimia de WoRMS resuelve la equivalencia), **~1.000 fotos mal etiquetadas reubicadas** (reidentificaciones de Minka) con manifiesto y rollback completo, y 57 fotos en cuarentena. Dos guardas nuevas en producción: (a) **guarda de margen k-NN** en AutoID (no se publica a especie si el margen top-1/top-2 es menor que 0,02 — esas filas aciertan el 53% en la evaluación de campo); (b) **guardián automático de correcciones de curadores** que retira nuestras identificaciones cuando un curador corrige a nivel clase o superior. Una **segunda opinión zero-shot para todo el catálogo** (embeddings de texto BioCLIP-2.5; 2.985 etiquetas) se usa como *rescate*: cuando el k-NN duda (similitud top-1 < 0,85) y el zero-shot coincide con otra especie con $p \geq 0,90$, gana el zero-shot — medido **+0,91 pp** en la evaluación de campo (772 arreglos / 315 roturas, 15% de cobertura) y ya en producción. El prior estacional temporal se **descartó** a escala completa (76,84% → 76,64% la mejor variante). Todo auditado: contaminación por prototipo (diario) y QA de fuga de las filas minadas (semanal, con purga automática).

Resumen

BioFauna identifica taxones mediterráneos (y algunos adyacentes incidentales) a partir de fotografías por **recuperación** sobre una galería regional, no entrenando un clasificador cerrado. El encoder de producción es **BioCLIP-2.5 ViT-H/14** (632M parámetros, embeddings de 1024 dimensiones), **congelado**. La consulta se embebe (fusión del encuadre global con un recorte central al 65%), se busca con **k-NN (k=15)** y un agregador de votos temperado, se puede reponderar con un prior geográfico, se convierte en probabilidad calibrada y, si el margen es débil, se **abstiene** a género, familia o un grupo de indistinguibilidad curado.

Corte de producción (2026-09-23, /health en vivo + calibration.json):

Magnitud	Valor
Galería	1.118.353 embeddings / 4.543 especies, FAISS alineado
Catálogo (lista mediterránea)	2.985 taxones (dataset/catalog.json)
Acierto fuera de muestra (sin fuga)	88,11% especie / 90,55% género / 92,46% familia
Evaluación	n=12.373 observaciones, 2.091 especies con ≥1 muestra (sin copias de la galería, O18)
Hardware	NVIDIA RTX 3060 12 GB (~4,4 GB VRAM en inferencia)

Esas cifras son **estratificadas por observación** y con control de fugas por embedding global (el 85,78% anterior sobre $n=19.087$ y el panel de 92–93% contenían copias de la galería: ver la actualización y O18). **No** se pueden comparar a ciegas con el 75,97% de agosto de 2026 ($n=12.788$, otra cosecha). Mezclar cohortes es el error que este proyecto ya documentó. Ambos números aparecen abajo, etiquetados por protocolo.

Una búsqueda sistemática de más top-1 de especie **entrenando sobre este espacio** (QLoRA, LoRA, triplet, ArcFace, cabeza lineal, SupCon acotado) **no superó** la recuperación congelada. Lo que sí se quedó en producción: escala del backbone, completitud/calidad de galería, fusión en inferencia, agregador k-NN temperado y abstención taxonómica. Publicamos el libro de experimentos, los IDs de taxón, los centroides y un identificador autoalojable. **No se redistribuyen fotos ni embeddings.npy por foto**; se pueden reconstruir desde Minka / iNaturalist / GBIF.

Palabras clave: BioCLIP-2.5, ViT-H, k-NN, clasificación visual fina, biodiversidad marina, ciencia ciudadana, abstención taxonómica, calibración, mar Mediterráneo

1. Introducción

El Mediterráneo concentra mucha biodiversidad marina en poca superficie, y hay pocos taxónomos. Minka e iNaturalist recogen fotos más rápido de lo que se identifican. Los clasificadores globales ayudan, pero endemismos, invertebrados crípticos y guías locales siguen siendo un cuello de botella.

BioFauna es el identificador de FotoFauna. Decisión de diseño: **no entrenar una CNN de conjunto cerrado**. Usar un encoder preentrenado en biología y una **galería regional** que puede crecer especie a especie sin reentrenar.

Aportaciones

- 1. Pila de recuperación en producción (ViT-H congelado + k-NN + calibración + abstención jerárquica) en GPU de consumo, con publicación automática a Minka cuando la confianza es alta.
- 2. Protocolo de evaluación **por observación**, con control de similitud a la galería tras un incidente de 42,7% de autoduplicados.
- 3. Un **libro de experimentos** (este texto §4 y [docs/EXPERIMENTS.md](#)): hipótesis, resultado y si se conservó.
- 4. Artefactos para reconstruir: IDs, centroides (4.702×1024), calibradores, priors geográficos, pares crípticos — no el corpus de fotos.

2. Sistema

2.1 Encoder

Propiedad	Valor
Checkpoint	hf-hub:imageomics/bioclclip-2.5-vith14
Arquitectura	ViT-H/14, ~632M params, 1024-d L2-normalizados
Entrada	224×224
Entrenamiento en BioFauna	Congelado

2.2 Identificación (producción, 2026-09-23)

1. Embeber la consulta; fusionar **encuadre global + recorte central 65%**.
2. Recuperar **k=15** vecinos (FAISS si hay galería completa; centroide más cercano con los prototipos publicados si no).
3. Agregar votos **temperados** $\Sigma \exp(\max(s, 0)/T)$, **T=0,05**, más un boost al prototipo. Cada especie aporta **como máximo 3** de los 15 vecinos al voto (KNN_CLASS_CAP=3, K23), para que una especie con una galería enorme no gane a una escasa solo por número.
4. Prior geográfico multiplicativo si hay GPS.
5. **Abstener** si el margen top-1/top-2 es pequeño y comparten género/familia, o si el par/género/grupo está en `dataset/taxonomic_exceptions.json`.
6. Pasar features k-NN → **P(acierto)** con regresión logística.

AutoID en FotoFauna publica si **p ≥ 0,80**. Con el calibrador reajustado sobre datos sin fuga (`created=2026-09-23T08:22`, ajuste 8.509 / test 3.864 filas, partición disjunta por especie) ese umbral da **97,0% de precisión con 80,6% de cobertura** en el test (conjunto cerrado; el KPI de observaciones recientes es más bajo, O16). La estimación de agosto (95,3% al 57,4%) queda superada.

Este repositorio publica **centroides** (`data/patterns/<slug>/prototype.npy`): basta para un demo nearest-centroid. El k-NN completo exige reconstruir embeddings por foto en local ([docs/dataset.md](#)).

2.3 Datos (producción vs lo publicado)

Capa	Producción	Este repo
Fotografías	~1,06 M en disco	No (licencia)
Embeddings por foto	1.118.353 vectores	No (tamaño + derivados de fotos)
Prototipo por especie	4.543×1024 float32	Sí (~15 MB)
IDs / nombres	2.985 filas	Sí (<code>dataset/catalog.json</code>)
Calibrador, geo, pares, excepciones	JSON vivo	Sí

Nombres contrastados con **WoRMS** (nombre aceptado junto al slug estable). Recortes de láminas de guía que mezclaban taxones bajo una etiqueta se cuarentenaron (1.088 fotos / 107 especies, auditoría de agosto 2026).

Tiers del catálogo: 0 heterobranquios (634), 1 resto marino (1.527), 2 terrestre/incidental (824).

3. Protocolo de evaluación

Los números de cabecera usan **observaciones** retenidas (un encuentro, a menudo varias fotos del mismo organismo), no un split aleatorio por foto. Un 80/20 a nivel foto infla k-NN y metric learning ~10 pp por ráfagas casi duplicadas.

Regla	Por qué
Estratificar por ID de observación	Sin fuga de ráfagas
Rechazar si es demasiado similar a la galería	Caza IDs perdidos tras migraciones

Regla	Por qué
Mismo protocolo entre ablaciones	McNemar comparable
No mezclar cosechas al citar un delta	Otro mix de especies $\neq$ ganancia de modelo

Incidente (23-sep-2026). La puerta de agosto de abajo tampoco funcionaba: comparaba un embedding promediado con TTA (original + recorte 90%) con los de la galería a coseno $>0,999$; una foto idéntica da $\sim 0,99$ así. El 50,8% del eval había vuelto a entrar en la galería. La puerta compara ahora el embedding **global** (el mismo que guarda la galería) a $\geq 0,98$, y un script de auditoría revisa todas las filas de eval tras cada crecimiento de galería (O18).

Incidente (25/26-ago-2026). La lista de IDs ya vistos apuntaba a una ruta abandonada y no coincidía con nada. El 42,7% de una cosecha de 22.332 fotos ya estaba en la galería. Con $k=15$ el titular solo se movió ~ 1 pp; con k pequeño la curva era absurda. Arreglo: embeber cada candidato y tirar near-duplicates. Sigue como puerta de la cosecha.

Dos métricas etiquetadas

Etiqueta	Cohorte	Top-1 especie	Uso
A — corte TTA	harvest_calib n=12.788 (ago 2026, sin fuga)	75,97% (luego 77,77% con pila de inferencia; 79,10% jsonl tras densificar)	Ablaciones comparables §4.1–4.2
B — calibrador vivo	calib_raw_t05 n=19.087 (2026-09-14)	85,78%	Histórico (afectado por la fuga O18)
C — sin fuga	calib_raw_t05 n=12.373 (2026-09-23, auditado, copias $\geq 0,98$ fuera)	88,11%	Informe de producción actual (§5)

B es más grande, cubre más especies difíciles y usa $T=0,05$ y campañas de calidad posteriores. **A no es “peor ingeniería”;** **B no es un salto mágico de 10 puntos sobre las mismas fotos.**

4. Experimentos

Cada fila: **hipótesis** → **resultado** → **qué aportó**. Detalle y McNemar: [docs/EXPERIMENTS.md](#).

4.1 Conservados (en producción)

ID	Qué se probó	Resultado	Aporte
K1	Galería ViT-L → ViT-H congelado	+6,8 pp (63,9% → 70,6% en aquella cohorte)	Mayor ganancia de modelo. Encoder de producción.
K2	Barrido k-NN estratificado	k=15	k de producción.
K3	Unificar SSD + archivo HDD y re-embeber	71,7% → 75,8% en n=12.788 limpio	Cerró el <i>archive gap</i> . Completitud > adapters.
K4	Calibración logística (10 features k-NN)	ECE $\sim 0,03$ vs $\sim 0,09$ coseno crudo	Umbral AutoID interpretable.
K5	Abstención jerárquica + pares/géneros expertos	Fallback género/familia $\sim 89\%$ cuando aplica	Salida más segura.
K6	TTA 90% y luego fusión ROI 65%	TTA +0,21–0,75 pp; ROI +1,63 pp vs solo global	Embedding de consulta.

ID	Qué se probó	Resultado	Aporte
K7	Fusión tardía de varias fotos de una observación	+0,79 pp global; +3,15 pp en el 25% multi-foto	Producción si N>1.
K8	Subespacio local Fisher / PCA+LDA en pares crípticos	+0,14 a +0,36 pp	Re-ranking acotado.
K9	Mismo mecanismo inter-género / misma familia	Re-cosecha oficial 77,77% (cohorte A + pila)	Segundo disparo en producción.
K10	Densificar galería (más/mejores fotos, encoder congelado)	jsonl cohorte A 79,10% ; swaps de calidad posteriores	Datos, no pesos. Galería viva 848.883.
K11	Agregador k-NN temperado T=0,05	McNemar n=8.000: +7,81 pp , 671/46	Scorer de producción (acumulativo con K10).
K12	Gate MiniCPM en dos pares	McNemar pequeño 12/1, p=0,003	Sidecar acotado, no VLM general.
K13	Auditor de nomenclatura WoRMS+GBIF	85 nombres aceptados; 4 fusiones de slug duplicado	Higiene de catálogo.
K14	Lista de indistinguibles + grupo esponjas	Pares extra desde confusión de eval	Capa de decisión donde la visión satura.
K19	Crece las fotos de referencia hasta ~1.000/especie donde las fuentes lo permiten + re-embed completo por especie	McNemar n=18.000: +0,57 pp (313/211, p=1e-5). Por especies: crecen $\geq +300$ vectores +7,7 pp , +100–299 +12,0 pp , +1–99 +3,4 pp; las que no crecen –0,63 pp (dilución)	Los datos funcionan donde existen; el 77% de los errores restantes está en especies que no cambiaron.
K20	Segunda oleada de crecimiento (121 especies, 21,9k fotos), reconstrucción a 1.118.353 vectores	McNemar n=21.000: +0,22 pp (84/38, p=5e-5); especies tocadas 83,3% → 89,5% (83/1); 31 mejoran, 0 empeoran	En producción el 21-sep-2026.
K21	Segunda opinión independiente para el recuperador de conjunto cerrado: BioCLIP zero-shot sobre una lista regional	300 observaciones de aves mediterráneas: BF $\geq 0,85$ y zero-shot $\geq 0,80$ coinciden → 98,5% de precisión con 69% de cobertura (BF solo 91,2% con 79%). Todos los grupos: 95,9% al 49% con nivel de rescate frente a BF solo 93,8% al 48%	Guarda open-set de AutoID (aves en producción; resto de grupos pendiente).
K23	Tope de votos por especie en el agregador k-NN (KNN_CLASS_CAP=3)	McNemar n=12.000 obs held-out: +1,13 pp (92,33% → 93,47%; 228 arreglos / 92 roturas); 177 especies mejoran / 70 empeoran ; más ganancia en especies con <25 fotos de galería (+3,2–3,5 pp). cap1 –0,19, cap2 +0,82, cap4 +1,08, cap5 +0,94 pp	En producción el 22-sep-2026 07:17 CEST. (Medido antes de la purga O18; cuenta la ganancia relativa.)
K22	Criterio de promoción contado en especies	173 especies mejoran / 153 empeoran / 2.186 sin cambio (índice anterior → actual)	Reportar el balance por especie junto a Δ y p.

4.2 Rechazados (no repetir tal cual)

ID	Qué se probó	Resultado	Aporte
R1	QLoRA ViT-L + proyección entrenable	1,7% especie	Fragilidad; no es “BioCLIP no se puede afinar” en general.
R2	QLoRA BioCLIP-2 ViT-L vs ViT-H	768 vs 1024-d	Descartado antes de evaluar.

ID	Qué se probó	Resultado	Aporte
R3	Triplet sobre ViT-H (8 variantes)	-0,7 a -7 pp	Este régimen memoriza.
R4	ArcFace sobre ViT-H congelado	Empate con k-NN	No sustituye la recuperación.
R5	LoRA+ArcFace 100 spp	+0,0 pp OOS	Los splits internos mentían.
R6	LoRA 4 bloques + ArcFace, 1.358 spp	-31,2 pp	Afinar un subconjunto envenena el espacio compartido.
R7	Cabeza lineal, backbone congelado	-0,6 a -1,1 pp OOS	Mini-set de train engañaba.
R8	Pesar recortes de guías	-0,9 pp	Lámina $\neq$ foto submarina.
R9	Quitar ráfagas near-duplicate	-1,6 pp	Las ráfagas ayudan al k-NN.
R10	Filtrar outliers de embedding	-0,21 a -1,45 pp	Se iba variación intraespecífica.
R11	Ensachar margen de abstención same-genus	Coste 9:1	τ de producción se queda estrecho.
R12	Re-rank “preferir epibionte”	-0,23 pp (64/116)	El huésped real entra como ruido top-k.
R13	Re-ranker SupCon en 20 pares	Loss de val diverge desde época 1; kill-switch antes del eval	Tercera arquitectura, mismo fallo.
R14	TTA con flip horizontal	-0,13 pp	La asimetría es señal.
R15	Peso de prototipo por dispersión de especie	-0,09 pp	Lo global no describe esta foto.
R16	Penalizar vecinos fuera de la familia consenso	-0,41 pp, p=0,0005	El voto mayoritario ya está mal en convergencia morfológica.
R17	Recorte guiado por atención	+0,04 pp, p=0,77	Ruido.
R18	Filtro por filo/clase	Todos los umbrales netos negativos	El 80% del error cruzado ya viene del k-NN.
R19	Subespacio ancestral si <5 refs	1 observación abordable	Cerrado antes de gastar GPU.
R20	Neutralizar fondo/sustrato	-0,92 pp vs control; -3,48 vs pila completa	El hábitat es señal en epibiontes.
R21	Prior geo extra (nubes Minka) encima del de producción	No significativo; 4/5 folds fuerza=0	Las confundibles conviven.
R22	Fusión DINOv2 (scripts mal llamados DINOv3)	-6,75 pp vs producción	DINOv2 solo-prototipo es mucho más débil aquí.
R23	Multi-prototipos k-means	No significativo; 4/5 folds blend=0	Un centroide basta para el boost.
R24	Re-embed marino selectivo (36 spp)	~0 pp	Sin cutover.
R25	VLM / densificación genérica en fanerógamas	Nulo	El swap de calidad ayudó a <i>Posidonia</i> , no a <i>Cymodocea</i> .

ID	Qué se probó	Resultado	Aporte
R26	Filtro MiniCPM “sujeto puro” en fauna (16 spp)	97,5% ya “puro”	No transfiere desde fanerógamas.
R27	Swap Q≥8 en taxones ya agotados	Rendimiento muy desigual	La calidad ayuda si hay fotos mejores.
R28	Subir el umbral de confianza para reducir errores confiados	Backtest vivo n=184; precisión plana 90–92% para $p \geq 0,80 \dots 0,95$; solo cae la cobertura (52% → 11%)	La calibración satura; no es palanca.
R29	Exigir acuerdo de iNaturalist CV antes de publicar	De 81 respuestas BF ≥0,85: iNat coincidió en 51 (BF acierta 96%), no devolvió nada en 29 (BF acierta 83%), discrepó en 1; ~4 aciertos bloqueados por cada error evitado	Sustituido por guardas de dominio + consenso zero-shot (prueba de 1 día, auditoría pendiente).

4.3 Fallos operativos (no son ideas de modelo; sí son públicos)

ID	Fallo	Efecto	Aporte
O1	Cosecha de calibración filtrada a la galería	Curvas de k pequeño infladas	Dedup por similitud obligatorio.
O2	Desync FAISS vs etiquetas tras /reload (1-sep-2026)	IDs vivos absurdas a 85–100%; evals en disco válidas	Recargar índice y labels juntos.
O3	Métricas de admin leyendo snapshots congelados	Panel in-sample / viejo	Métricas desde el jsonl actual.
O4	- - species vacío tras SSH anidado (13-sep-2026)	Swap de calidad en taxones de más ~35 min	Pasar ficheros de slugs, nunca listas interpoladas.
O12	El servicio traducía las etiquetas de FAISS con la lista viva de carpetas de especies, no con la lista de nombres del propio índice; tres carpetas nuevas desplazaron todas las etiquetas mientras /health seguía diciendo alineado	Especie equivocada con similitud 0,92 durante horas (20/21-sep-2026); AutoID no publicó nada	Cron guardián compara nombres del índice ↔ especies cargadas ↔ carpetas (amplía O2).
O13	Un trabajo desatendido reconstruyó el directorio FAISS de producción y refiteó la calibración antes de validar	Índice de producción sobrescrito por una build sin validar	Los trabajos desatendidos nunca escriben rutas de producción.
O14	La web de Minka devuelve 403 al User-Agent por defecto de python-httpx (login y descargas de fotos)	AutoID sin publicar durante días (segunda recurrencia de la clase «cabecera ausente»)	Un único cliente HTTP compartido; alarma de días sin publicaciones.
O15	Dos sesiones de agente ejecutaron el mismo ciclo en paralelo; una promoción sobrescribió la otra; OOM de GPU con sidecar + servicio + reembed	Cómputo duplicado; desajuste índice/calibración ~30 min	Sesión activa única con registro escrito.
O16	Evaluación de conjunto cerrado y correlada por observador: panel 92,4% frente a ~80% en 300 observaciones recientes research grade; el 12% de las observaciones de aves son especies fuera del catálogo	El panel sobreestima la precisión real	Muestra de observaciones recientes como KPI operativo.

ID	Fallo	Efecto	Aporte
O18	La puerta de fuga del eval comparaba un embedding promediado con TTA con umbral 0,999; una foto idéntica da ~0,99 y la puerta nunca saltaba. Las búsquedas ad hoc posteriores (Wikimedia/GBIF/iNat de cualquier grado) no tenían puerta	El 50,8% de las filas de eval eran copias de la galería; panel 92,4–93,4% frente a 88,1% limpio; el 24% real en especies raras con fotos no vistas aparecía como 57%	Puerta con embedding global $\geq 0,98$ en todas las cosechas; <code>leak_audit_calib.py</code> tras cada crecimiento; filas con fuga apartadas y calibrador reajustado (23-sep-2026).
O17	La precisión por especie de los paneles solo cambia cuando el eval se re-puntúa contra el índice servido	Cifras congeladas tras promociones	Re-score diario automático; re-score tras cada promoción.

Actualización 2026-09-23 — fuga en la evaluación detectada y eliminada. Una auditoría que embebe cada foto de evaluación en *global* (sin TTA, igual que la galería) y la compara con la galería de su propia especie encontró que el **30,0%** de las 25.143 filas de evaluación eran copias exactas de una foto de la galería (coseno $\geq 0,995$) y el **50,8%** copias o copias reescaladas/recortadas ($\geq 0,98$). El filtro de fuga de la cosecha comparaba un embedding *promediado con TTA* contra un umbral de 0,999 que una imagen idéntica nunca alcanza (~0,99), así que dejaba pasar todo tras el arreglo de agosto (§3). Las filas con fuga acertaban el **97,6%**; las limpias dan **88,11%** especie / 90,55% género / 92,46% familia (n=12.373, 2.091 especies). La cifra de panel de 92,4–93,4% citada el 21/22-sep queda retirada; **88,1% es la cifra actual de conjunto cerrado**, y el KPI de ~80% sobre observaciones recientes (O16) sigue siendo la cifra operativa. En especies raras con fotos nuevas de verdad de otras fuentes (Wikimedia, GBIF, museos) el acierto fue solo del **24%** (n=130): la fuga lo ocultaba. Filtro arreglado en todas las cosechas, filas con fuga apartadas (no borradas) y calibrador reajustado con datos limpios (O18). También en producción desde el 22-sep: tope de 3 votos por especie en el agregador k-NN (K23).

Actualización 2026-09-21. Producción sirve ahora **1.118.353** embeddings / **4.543** especies (1.720 son clases de galería fuera del catálogo de 2.985 especies: 1,8% de los vectores) tras dos oleadas de crecimiento (K19–K20). El panel (overlay fuera de muestra, n=24.475) marca **92,36%** de especie; una comprobación sobre 300 observaciones recientes research grade de Minka da ~**80%** (aves del catálogo 84% frente a 96% en el panel): el panel es una evaluación de conjunto cerrado y sobreestima la precisión real (O16). El recuperador de conjunto cerrado responde con confianza a especies que no están en el catálogo; una segunda opinión independiente de BioCLIP zero-shot elimina la mayoría de esos errores en aves (K21).

5. Informe de producción actual (cohorte C, sin fuga, 2026-09-23)

Nivel	Acierto	n
Especie	88,11%	12.373
Género	90,55%	12.373
Familia	92,46%	12.373
Tier 0 (heterobranquios)	85,12%	2.446
Tier 1 (otros marinos)	87,72%	5.633
Tier 2 (terrestres/incidentales)	90,34%	4.294

Por especie (2.091 con eval limpio): 1.429 al 100%, 431 por debajo del 80%. 894 especies del catálogo perdieron sus únicas filas de eval en la purga y se están volviendo a cosechar con la puerta arreglada. La cohorte B de abajo se conserva como histórico; estaba afectada por la misma fuga.

Cohorte B (histórico, 14-sep)

Nivel	Acierto	n
Especie	85,78%	19.087
Género	89,15%	19.087
Familia	91,41%	19.087
Tier 0 (heterobranquios)	76,86%	2.528
Tier 1 (resto marino)	86,56%	10.207
Tier 2 (terrestre/incidental)	88,08%	6.352

El error que queda es sobre todo **cripsis y convergencia morfológica**, no “hace falta LoRA”. Casi todo el catálogo tiene ≥ 1 observación retenida; una cola pequeña está agotada en Minka+iNaturalist.

Fanerógamas (n=60, 14-sep): *Posidonia oceanica* 73,3%; *Cymodocea nodosa* 70,0% (swap de calidad **no** pasado a producción); *Nanozostera noltii* 86,7%; *Zostera marina* 75,0%. El par *Z. marina* ↔ *N. noltii* pasó a abstención experta (20/120 confusiones cruzadas).

6. Limitaciones

1. El top-1 de especie no es nivel experto en invertebrados crípticos.
2. No hay estudio de generalización fuera del Mediterráneo.
3. El código público es un **identificador de reconstrucción**, no el volcado del servicio de 1.300 líneas de HanSolo.
4. La tabla precisión/cobertura de AutoID es anterior al calibrador del 14-sep.
5. Las correcciones de curadores aún no cierran un bucle de entrenamiento.
6. **Recuperación de conjunto cerrado**: las especies ausentes del catálogo reciben una respuesta errónea con confianza; el calibrador solo vio especies del catálogo. Mitigado en aves con una guarda de consenso zero-shot (K21); todavía no en otros grupos.
7. **Optimismo de la evaluación**: la métrica del panel sin fuga (88,1%) sigue siendo de conjunto cerrado y correlada por observador; una muestra de observaciones recientes (~80%) es el KPI operativo (O16). Hasta el 23-sep el panel contenía además copias de la galería (O18).
8. **AutoID sin verificación de iNaturalist** solo lleva un día en marcha (guardas: caja mediterránea, consenso en aves, tope horario, ahora 30/h y 1.000/día; al llegar al tope de la hora se pausa esa hora en vez de disparar el cortocircuito); la auditoría contra identificaciones de la comunidad está pendiente.

7. Reproducibilidad

```
git clone https://github.com/yespi/biofauna.git && cd biofauna
pip install -r requirements.txt
```

```
python -m uvicorn src.identify_service:app --host 0.0.0.0 --port 8090
```

Descarga BioCLIP-2.5 de Hugging Face al primer arranque. Usa prototipos en `data/patterns/`. Para reconstruir la galería completa: bajar fotos con los IDs de `dataset/catalog.json`, `scripts/reembed_vith.py`, dejar `embeddings.npy` junto a cada prototipo.

Licencia MIT para código y JSON/prototipos publicados. El copyright de las fotos sigue en observadores y plataformas.

Agradecimientos

Xavier Salvador, Miquel Pontes y Manuel Ballesteros (GROC/OPK). Comunidades Minka e iNaturalist. WoRMS. BioCLIP (Stevens et al.).

Disponibilidad de datos

Código, prototipos, catálogo, calibradores, priors, pares crípticos: este repositorio. Backbone: Hugging Face `imageomics/bioclclip-2.5-vith14`. Imágenes: Minka/iNaturalist/GBIF por separado.

Referencias

Las mismas que la versión inglesa (`01_biofauna.md`).

Informe técnico del repositorio abierto. No es un envío a revista. Sedes posibles tras un PDF congelado: Ecological Informatics / Biodiversity Data Journal / PeerJ.

7. Cómo identifica BioFauna una especie

 Pipeline: de la fotografía a una respuesta calibrada y con guardas

BioFauna is a **retrieval** classifier, not a trained end-to-end network:


1. **Frozen encoder.** Every gallery photograph is embedded with **BioCLIP-2.5 ViT-H/14** (frozen, no fine-tuning). The query image is embedded the same way, as the global vector **plus a 65 % region-of-interest fusion** (the subject-centred crop), L2-normalised.
2. **Approximate search.** A **FAISS** index holds all gallery vectors (currently **1.12 M vectors / 4,543 species**, row-aligned so that each vector maps to exactly one species).
3. **k-NN with a tempered aggregator.** The $k=15$ neighbours vote with weights $\exp(\text{similarity} / T)$, $T=0.05$, **capped at 3 votes per species** so that a single over-represented species cannot swamp the vote.
4. **Context corrections.** A **geographic prior** (1,386 species, $\sigma \approx 200$ km) and **cryptic-pair** handling (Fisher directions / local subspace) correct the ranking when two species are visually almost identical.

5. **Hierarchical calibration.** A per-species logistic model converts the k-NN score into a **calibrated probability**, with genus- and family-level fallbacks; below the calibrated threshold the service **abstains** to genus/family instead of guessing.
6. **Zero-shot rescue (2026).** When the top-1 similarity is low (< 0.85), a **catalogue-wide zero-shot** comparison (2,985 text labels) is consulted; if it agrees with a *different* species at $p \geq 0.90$, it wins. Measured effect: **+0.91 pp** on the field evaluation.
7. **Publication guards (AutoID).** A species is not published when the top-1/top-2 similarity **margin** < 0.02 , when the observation falls outside the domain, or when a vocal disagreement exists; a **curator guard** automatically retracts our identifications when a curator corrects at class level or above.

8. Cómo ha mejorado el modelo, paso a paso

2 - Como ha mejorado el modelo, paso a paso

Acierto por especie en la evaluación oficial de cada etapa. La serie NO es comparable punto a punto: la vara de medir también se hizo más honesta.



etapa	cambio	efecto
YOLOFauna (2024–2026)	BioCLIP ViT-L + k-NN	63.9 %
Aug 2026	full re-embedding with BioCLIP-2.5 ViT-H/14	70.6 %
Aug 2026	k=15 + hierarchical fallback + calibration hygiene	71.7 %
Aug 2026	hierarchical calibration (species/genus/family)	74.1 %
Sep 2026	3-vote cap per species, ROI fusion, geographic prior	77.9 %
Sep 2026	evaluation leak fixed → honest panel (near-100 % of the drop was leakage, not error)	79.4 %
Sep 2026	gallery hygiene : 135 duplicate synonym slugs merged (Minka authority), ~1,000 mislabelled photos relocated, 57 quarantined	79.6 %
Sep 2026	zero-shot rescue + publication guards	79.6 % (+0.91 pp on the same rows; the headline moves with the evaluation)


Two lessons that shaped the project: (a) **the evaluation is part of the model** — an unfixed leak in the evaluation made the system look better than it was; (b) **gallery quality beats model complexity** — synonyms, contamination and

mislabelled observations cost more accuracy than any hyper-parameter we tuned (LoRA/QLoRA/triplet/ArcFace/SupCon on this embedding space were all rejected by measurement).

9. Datos, evaluación y operación

3 - Datos, evaluacion y operacion

Una sola copia de las fotos; todo cambio de produccion se mide y se puede revertir.



QA continuo: contaminacion de galeria (diario), fuga del eval minado (semanal, con purga), alineacion indice-catalogo (cada 10 min).

Objetivo: acercar el acierto por especie al 100 % con galeria (mas fotos de calidad, menos contaminacion) y evaluacion honesta.

- **Sources** (public images): **Minka SDG** 377,476 · **iNaturalist** 779,411 · GBIF 39,570 · Wikimedia Commons 6,677 · DORIS/FFESSM 5,091 · SeaSlugForum 3,147 · WoRMS 1,320 · FishBase 1,072 → **≈1.22 M photographs**.
- **One copy of each photo**, never deleted; every relocation is done with a manifest and a rollback script.
- **Field evaluation**: field-only photographs (iNaturalist/Minka research grade), 20–30 per species, leak-audited before merging (a gallery copy in the evaluation would inflate the score).
- **Every production change is measured** (McNemar + per-species guard); the previous index stays as a **24-h rollback**.
- **Continuous QA**: gallery contamination (prototype-centroid metric, daily), mined-evaluation leak audit (weekly, with automatic purge), index ↔ catalogue alignment (every 10 min).