

BioFauna: identificación de taxones mediterráneos por recuperación sobre BioCLIP-2.5 ViT-H congelado

Autor: Gustavo Zafra (Yespi)

Aportación taxonómica: Xavier Salvador, Miquel Pontes, Manuel Ballesteros

Repositorio: <https://github.com/yespi/biofauna>

Sistema en vivo: <https://fotofauna.yespi.es>

Versión del manuscrito: 2026-10-09 (artículo para Biodiversity Data Journal / PeerJ)

Nombre. El proyecto se llamó YOLOFauna (2024–mediados de 2026); pasó a BioFauna cuando producción se quedó en recuperación BioCLIP, no en detectores YOLO. Origen: [docs/HISTORY.md](#).

Resumen

BioFauna identifica taxones mediterráneos (y algunos adyacentes) a partir de fotografías por **recuperación** sobre una galería regional, sin entrenar un clasificador cerrado. El encoder de producción es **BioCLIP-2.5 ViT-H/14** (congelado; embeddings de 1024 dimensiones). La consulta se embebe (fusión del encuadre global con un recorte central al 65 %), se busca con **k-NN (k = 15)** y un agregador de votos temperado, se puede reponderar con un prior geográfico, se convierte en probabilidad calibrada y, si el margen es débil, se **abstiene** a género, familia o un grupo de indistinguibilidad curado.

Cifras vigentes (dataset/stats.json tras promote *all08it2*, 8-oct-2026): galería en vivo **1.198.265** embeddings / **4.543** especies; panel de campo **78.145** filas con acierto de especie fuera de muestra **83,14** % (género 87,9 %, familia 91,0 %). AutoID publica con umbral de especie **0,83** (precisión ≈96 %, cobertura ≈66,5 % en el eval completo). Líneas base sobre 78.180 filas (2026-10-03): centroide más cercano **74,73** %; k-NN simple **79,86** %. Una búsqueda sistemática de mejoras entrenando sobre este espacio (LoRA, QLoRA, ArcFace, etc.) **no superó** la recuperación congelada. Publicamos el libro de experimentos, IDs de taxón, centroides y un identificador autoalojable; **no** se redistribuyen fotos ni embeddings por foto.

Palabras clave: BioCLIP-2.5, ViT-H, k-NN, clasificación visual fina, biodiversidad marina, ciencia ciudadana, abstención taxonómica, calibración, mar Mediterráneo

1. Introducción

El Mediterráneo concentra mucha biodiversidad marina en poca superficie, y hay pocos taxónomos. Minka e iNaturalist recogen fotos más rápido de lo que se identifican. Los clasificadores globales ayudan, pero endemismos, invertebrados crípticos y guías locales siguen siendo un cuello de botella.

BioFauna es el identificador de FotoFauna. Decisión de diseño: **no entrenar una CNN de conjunto cerrado**. Usar un encoder preentrenado en biología y una **galería regional** que puede crecer especie a especie sin reentrenar.

Aportaciones

1. Pila de recuperación en producción (ViT-H congelado + k-NN + calibración + abstención jerárquica) en GPU de consumo, con publicación automática a Minka cuando la confianza es alta.
2. Protocolo de evaluación **por observación**, con control de similitud a la galería tras un incidente de 42,7% de autoduplicados.

3. Un **libro de experimentos** (este texto §4 y [docs/EXPERIMENTS.md](#)): hipótesis, resultado y si se conservó.
4. Artefactos para reconstruir: IDs, centroides (4.702×1024), calibradores, priors geográficos, pares crípticos — no el corpus de fotos.

2. Sistema

2.1 Encoder

Propiedad	Valor
Checkpoint	hf-hub:imageomics/bioclip-2.5-vith14
Arquitectura	ViT-H/14, ~632M params, 1024-d L2-normalizados
Entrada	224×224
Entrenamiento en BioFauna	Congelado

2.2 Identificación (producción, 2026-09-23)

1. Embeber la consulta; fusionar **encuadre global + recorte central 65%**.
2. Recuperar **k=15** vecinos (FAISS si hay galería completa; centroide más cercano con los prototipos publicados si no).
3. Agregar votos **temperados** $\Sigma \exp(\max(s, 0)/T)$, **T=0,05**, más un boost al prototipo. Cada especie aporta **como máximo 3** de los 15 vecinos al voto (KNN_CLASS_CAP=3, K23), para que una especie con una galería enorme no gane a una escasa solo por número.
4. Prior geográfico multiplicativo si hay GPS.
5. **Abstener** si el margen top-1/top-2 es pequeño y comparten género/familia, o si el par/género/grupo está en dataset/taxonomic_exceptions.json.
6. Pasar features k-NN → **P(acierto)** con regresión logística.

AutoID en FotoFauna publica si **p ≥ 0,80**. Con el calibrador reajustado sobre datos sin fuga (created=2026-09-23T08:22, ajuste 8.509 / test 3.864 filas, partición disjunta por especie) ese umbral da **97,0% de precisión con 80,6% de cobertura** en el test (conjunto cerrado; el KPI de observaciones recientes es más bajo, O16). La estimación de agosto (95,3% al 57,4%) queda superada.

Este repositorio publica **centroides** (data/patterns/<slug>/prototype.npy): basta para un demo nearest-centroid. El k-NN completo exige reconstruir embeddings por foto en local ([docs/dataset.md](#)).

2.3 Datos (producción vs lo publicado)

Capa	Producción	Este repo
Fotografías	~1,06 M en disco	No (licencia)
Embeddings por foto	1.118.353 vectores	No (tamaño + derivados de fotos)
Prototipo por especie	4.543×1024 float32	Sí (~15 MB)
IDs / nombres	2.985 filas	Sí (dataset/catalog.json)
Calibrador, geo, pares, excepciones	JSON vivo	Sí

Nombres contrastados con **WoRMS** (nombre aceptado junto al slug estable). Recortes de láminas de guía que mezclaban taxones bajo una etiqueta se cuarentenaron (1.088 fotos / 107 especies, auditoría de agosto 2026).

Tiers del catálogo: 0 heterobranquios (634), 1 resto marino (1.527), 2 terrestre/incidental (824).

3. Protocolo de evaluación

Los números de cabecera usan **observaciones** retenidas (un encuentro, a menudo varias fotos del mismo organismo), no un split aleatorio por foto. Un 80/20 a nivel foto infla k-NN y metric learning ~10 pp por ráfagas casi duplicadas.

Regla	Por qué
Estratificar por ID de observación	Sin fuga de ráfagas
Rechazar si es demasiado similar a la galería	Caza IDs perdidos tras migraciones
Mismo protocolo entre ablaciones	McNemar comparable
No mezclar cosechas al citar un delta	Otro mix de especies ≠ ganancia de modelo

Incidente (23-sep-2026). La puerta de agosto de abajo tampoco funcionaba: comparaba un embedding promediado con TTA (original + recorte 90%) con los de la galería a coseno >0,999; una foto idéntica da ~0,99 así. El 50,8% del eval había vuelto a entrar en la galería. La puerta compara ahora el embedding **global** (el mismo que guarda la galería) a **≥0,98**, y un script de auditoría revisa todas las filas de eval tras cada crecimiento de galería (O18).

Incidente (25/26-ago-2026). La lista de IDs ya vistos apuntaba a una ruta abandonada y no coincidía con nada. El **42,7%** de una cosecha de 22.332 fotos ya estaba en la galería. Con k=15 el titular solo se movió ~1 pp; con k pequeño la curva era absurda. Arreglo: embeber cada candidato y tirar near-duplicates. Sigue como puerta de la cosecha.

Dos métricas etiquetadas

Etiqueta	Cohorte	Top-1 especie	Uso
A — corte TTA	harvest_calib n=12.788 (ago 2026, sin fuga)	75,97% (luego 77,77% con pila de inferencia; 79,10% jsonl tras densificar)	Ablaciones comparables §4.1–4.2
B — calibrador vivo	calib_raw_t05 n=19.087 (2026-09-14)	85,78%	Histórico (afectado por la fuga O18)
C — sin fuga	calib_raw_t05 n=12.373 (2026-09-23, auditado, copias ≥0,98 fuera)	88,11%	Informe de producción actual (§5)

B es más grande, cubre más especies difíciles y usa T=0,05 y campañas de calidad posteriores. **A no es “peor ingeniería”**; **B no es un salto mágico de 10 puntos sobre las mismas fotos.**

4. Experimentos

Cada fila: **hipótesis** → **resultado** → **qué aportó**. Detalle y McNemar: [docs/EXPERIMENTS.md](#).

4.1 Conservados (en producción)

ID	Qué se probó	Resultado	Aporte
K1	Galería ViT-L → ViT-H congelado	+6,8 pp (63,9% → 70,6% en aquella cohorte)	Mayor ganancia de modelo. Encoder de producción.
K2	Barrido k-NN estratificado	k=15	k de producción.
K3	Unificar SSD + archivo HDD y re-embeber	71,7% → 75,8% en n=12.788 limpio	Cerró el <i>archive gap</i> . Completitud > adapters.

ID	Qué se probó	Resultado	Aporte
K4	Calibración logística (10 features k-NN)	ECE ~0,03 vs ~0,09 coseno crudo	Umbral AutoID interpretable.
K5	Abstención jerárquica + pares/géneros expertos	Fallback género/familia ~89% cuando aplica	Salida más segura.
K6	TTA 90% y luego fusión ROI 65%	TTA +0,21–0,75 pp; ROI +1,63 pp vs solo global	Embedding de consulta.
K7	Fusión tardía de varias fotos de una observación	+0,79 pp global; +3,15 pp en el 25% multi-foto	Producción si N>1.
K8	Subespacio local Fisher / PCA+LDA en pares crípticos	+0,14 a +0,36 pp	Re-ranking acotado.
K9	Mismo mecanismo inter-género / misma familia	Re-cosecha oficial 77,77% (cohorte A + pila)	Segundo disparo en producción.
K10	Densificar galería (más/mejores fotos, encoder congelado)	jsonl cohorte A 79,10% ; swaps de calidad posteriores	Datos, no pesos. Galería viva 848.883.
K11	Agregador k-NN temperado T=0,05	McNemar n=8.000: +7,81 pp , 671/46	Scorer de producción (acumulativo con K10).
K12	Gate MiniCPM en dos pares	McNemar pequeño 12/1, p=0,003	Sidecar acotado, no VLM general.
K13	Auditor de nomenclatura WoRMS+GBIF	85 nombres aceptados; 4 fusiones de slug duplicado	Higiene de catálogo.
K14	Lista de indistinguibles + grupo esponjas	Pares extra desde confusión de eval	Capa de decisión donde la visión satura.
K19	Creer las fotos de referencia hasta ~1.000/especie donde las fuentes lo permiten + re-embed completo por especie	McNemar n=18.000: +0,57 pp (313/211, p=1e-5). Por especies: crecen ≥ 300 vectores +7,7 pp , +100–299 +12,0 pp , +1–99 +3,4 pp; las que no crecen –0,63 pp (dilución)	Los datos funcionan donde existen; el 77% de los errores restantes está en especies que no cambiaron.
K20	Segunda oleada de crecimiento (121 especies, 21,9k fotos), reconstrucción a 1.118.353 vectores	McNemar n=21.000: +0,22 pp (84/38, p=5e-5); especies tocadas 83,3% → 89,5% (83/1); 31 mejoran, 0 empeoran	En producción el 21-sep-2026.
K21	Segunda opinión independiente para el recuperador de conjunto cerrado: BioCLIP zero-shot sobre una lista regional	300 observaciones de aves mediterráneas: BF $\geq 0,85$ y zero-shot $\geq 0,80$ coinciden → 98,5% de precisión con 69% de cobertura (BF solo 91,2% con 79%). Todos los grupos: 95,9% al 49% con nivel de rescate frente a BF solo 93,8% al 48%	Guarda open-set de AutoID (aves en producción; resto de grupos pendiente).
K23	Tope de votos por especie en el agregador k-NN (KNN_CLASS_CAP=3)	McNemar n=12.000 obs held-out: +1,13 pp (92,33% → 93,47%; 228 arreglos / 92 roturas); 177 especies mejoran / 70 empeoran ; más ganancia en especies con <25 fotos de galería (+3,2–3,5 pp). cap1 –0,19, cap2 +0,82, cap4 +1,08, cap5 +0,94 pp	En producción el 22-sep-2026 07:17 CEST. (Medido antes de la purga O18; cuenta la ganancia relativa.)
K22	Criterio de promoción contado en especies	173 especies mejoran / 153 empeoran / 2.186 sin cambio (índice anterior → actual)	Reportar el balance por especie junto a Δ y p.

4.2 Rechazados (no repetir tal cual)

ID	Qué se probó	Resultado	Aporte
R1	QLoRA ViT-L + proyección entrenable	1,7% especie	Fragilidad; no es “BioCLIP no se puede afinar” en general.
R2	QLoRA BioCLIP-2 ViT-L vs ViT-H	768 vs 1024-d	Descartado antes de evaluar.
R3	Triplet sobre ViT-H (8 variantes)	–0,7 a –7 pp	Este régimen memoriza.
R4	ArcFace sobre ViT-H congelado	Empate con k-NN	No sustituye la recuperación.

ID	Qué se probó	Resultado	Aporte
R5	LoRA+ArcFace 100 spp	+0,0 pp OOS	Los splits internos mentían.
R6	LoRA 4 bloques + ArcFace, 1.358 spp	−31,2 pp	Afinar un subconjunto envenena el espacio compartido.
R7	Cabeza lineal, backbone congelado	−0,6 a −1,1 pp OOS	Mini-set de train engañaba.
R8	Pesar recortes de guías	−0,9 pp	Lámina ≠ foto submarina.
R9	Quitar ráfagas near-duplicate	−1,6 pp	Las ráfagas ayudan al k-NN.
R10	Filtrar outliers de embedding	−0,21 a −1,45 pp	Se iba variación intraespecífica.
R11	Ensachar margen de abstención same-genus	Coste 9:1	τ de producción se queda estrecho.
R12	Re-rank “preferir epibionte”	−0,23 pp (64/116)	El huésped real entra como ruido top-k.
R13	Re-ranker SupCon en 20 pares	Loss de val diverge desde época 1; kill-switch antes del eval	Tercera arquitectura, mismo fallo.
R14	TTA con flip horizontal	−0,13 pp	La asimetría es señal.
R15	Peso de prototipo por dispersión de especie	−0,09 pp	Lo global no describe esta foto.
R16	Penalizar vecinos fuera de la familia consenso	−0,41 pp, $p=0,0005$	El voto mayoritario ya está mal en convergencia morfológica.
R17	Recorte guiado por atención	+0,04 pp, $p=0,77$	Ruido.
R18	Filtro por filo/clase	Todos los umbrales netos negativos	El 80% del error cruzado ya viene del k-NN.
R19	Subespacio ancestral si <5 refs	1 observación abordable	Cerrado antes de gastar GPU.
R20	Neutralizar fondo/sustrato	−0,92 pp vs control; −3,48 vs pila completa	El hábitat es señal en epibiontes.
R21	Prior geo extra (nubes Minka) encima del de producción	No significativo; 4/5 folds fuerza=0	Las confundibles conviven.
R22	Fusión DINOv2 (scripts mal llamados DINOv3)	−6,75 pp vs producción	DINOv2 solo-prototipo es mucho más débil aquí.
R23	Multi-prototipos k-means	No significativo; 4/5 folds blend=0	Un centroide basta para el boost.
R24	Re-embed marino selectivo (36 spp)	~0 pp	Sin cutover.
R25	VLM / densificación genérica en fanerógamas	Nulo	El swap de calidad ayudó a <i>Posidonia</i> , no a <i>Cymodocea</i> .
R26	Filtro MiniCPM “sujeto puro” en fauna (16 spp)	97,5% ya “puro”	No transfiere desde fanerógamas.
R27	Swap $Q \geq 8$ en taxones ya agotados	Rendimiento muy desigual	La calidad ayuda si hay fotos mejores.
R28	Subir el umbral de confianza para reducir errores confiados	Backtest vivo $n=184$: precisión plana 90–92% para $p \geq 0,80 \dots 0,95$; solo cae la cobertura (52% → 11%)	La calibración satura; no es palanca.
R29	Exigir acuerdo de iNaturalist CV antes de publicar	De 81 respuestas BF $\geq 0,85$: iNat coincidió en 51 (BF acierta 96%), no devolvió nada en 29 (BF acierta 83%), discrepó en 1; ~4 aciertos bloqueados por cada error evitado	Sustituido por guardas de dominio + consenso zero-shot (prueba de 1 día, auditoría pendiente).

4.3 Fallos operativos (no son ideas de modelo; sí son públicos)

ID	Fallo	Efecto	Aporte
O1	Cosecha de calibración filtrada a la galería	Curvas de k pequeño infladas	Dedup por similitud obligatorio.
O2	Desync FAISS vs etiquetas tras /reload (1-sep-2026)	IDs vivos absurdas a 85–100%; evals en disco válidas	Recargar índice y labels juntos.
O3	Métricas de admin leyendo snapshots congelados	Panel in-sample / viejo	Métricas desde el jsonl actual.
O4	- -species vacío tras SSH anidado (13-sep-2026)	Swap de calidad en taxones de más ~35 min	Pasar ficheros de slugs, nunca listas interpoladas.
O12	El servicio traducía las etiquetas de FAISS con la lista viva de carpetas de especies, no con la lista de nombres del propio índice; tres carpetas nuevas desplazaron todas las etiquetas mientras /health seguía diciendo alineado	Especie equivocada con similitud 0,92 durante horas (20/21-sep-2026); AutoID no publicó nada	Cron guardián compara nombres del índice ↔ especies cargadas ↔ carpetas (amplía O2).
O13	Un trabajo desatendido reconstruyó el directorio FAISS de producción y refiteó la calibración antes de validar	Índice de producción sobrescrito por una build sin validar	Los trabajos desatendidos nunca escriben rutas de producción.
O14	La web de Minka devuelve 403 al User-Agent por defecto de python-httpx (login y descargas de fotos)	AutoID sin publicar durante días (segunda recurrencia de la clase «cabecera ausente»)	Un único cliente HTTP compartido; alarma de días sin publicaciones.
O15	Dos sesiones de agente ejecutaron el mismo ciclo en paralelo; una promoción sobrescribió la otra; OOM de GPU con sidecar + servicio + reembed	Cómputo duplicado; desajuste índice/calibración ~30 min	Sesión activa única con registro escrito.
O16	Evaluación de conjunto cerrado y correlada por observador: panel 92,4% frente a ~80% en 300 observaciones recientes research grade; el 12% de las observaciones de aves son especies fuera del catálogo	El panel sobreestima la precisión real	Muestra de observaciones recientes como KPI operativo.
O18	La puerta de fuga del eval comparaba un embedding promediado con TTA con umbral 0,999; una foto idéntica da ~0,99 y la puerta nunca saltaba. Las búsquedas ad hoc posteriores (Wikimedia/GBIF/iNat de cualquier grado) no tenían puerta	El 50,8% de las filas de eval eran copias de la galería; panel 92,4–93,4% frente a 88,1% limpio; el 24% real en especies raras con fotos no vistas aparecía como 57%	Puerta con embedding global ≥0,98 en todas las cosechas; leak_audit_calib.py tras cada crecimiento; filas con fuga apartadas y calibrador reajustado (23-sep-2026).
O17	La precisión por especie de los paneles solo cambia cuando el eval se re-puntúa contra el índice servido	Cifras congeladas tras promociones	Re-score diario automático; re-score tras cada promoción.

5. Informe de producción actual (cohorte C, sin fuga, 2026-09-23)

Nivel	Acierto	n
Especie	88,11%	12.373
Género	90,55%	12.373
Familia	92,46%	12.373
Tier 0 (heterobranquios)	85,12%	2.446
Tier 1 (otros marinos)	87,72%	5.633
Tier 2 (terrestres/incidentales)	90,34%	4.294

Por especie (2.091 con eval limpio): 1.429 al 100%, 431 por debajo del 80%. 894 especies del catálogo perdieron sus únicas filas de eval en la purga y se están volviendo a cosechar con la puerta arreglada. La cohorte B de abajo se conserva como histórico; estaba afectada por la misma fuga.

Cohorte B (histórico, 14-sep)

Nivel	Acierto	n
Especie	85,78%	19.087
Género	89,15%	19.087
Familia	91,41%	19.087
Tier 0 (heterobranquios)	76,86%	2.528
Tier 1 (resto marino)	86,56%	10.207
Tier 2 (terrestre/incidental)	88,08%	6.352

El error que queda es sobre todo **cripsis y convergencia morfológica**, no “hace falta LoRA”. Casi todo el catálogo tiene ≥1 observación retenida; una cola pequeña está agotada en Minka+iNaturalist.

Fanerógamas (n=60, 14-sep): *Posidonia oceanica* 73,3%; *Cymodocea nodosa* 70,0% (swap de calidad **no** pasado a producción); *Nanozostera noltii* 86,7%; *Zostera marina* 75,0%. El par *Z. marina* ↔ *N. noltii* pasó a abstención experta (20/120 confusiones cruzadas).

5.1 Informe de campo por bloques (2026-10-02, todas las cifras medidas)

Galería. 1.118.321 vectores / 4.543 especies de iNaturalist 733.789 fotos, Minka 372.347, GBIF 39.570, DORIS/FFESSM 5.091, Wikimedia 4.197, WoRMS 1.319, SeaSlugForum 817, FishBase 646. Vectores por especie: 775 especies tienen menos de 10, 1.058 tienen 10–29, 450 tienen 30–99, 1.123 tienen 100–299, 935 tienen 300–999 y 202 tienen 1.000 o más (mediana 97, máximo 3.223); la galería es de cola larga muy marcada.

Acierto de campo (especie).

Bloque	Filas	Acierto	Salvedad
Conjunto de evaluación original (comparable con todas las versiones anteriores)	60.743	81,18 %	correlado por observador, conjunto cerrado
Ronda 1 de minería (tras purga)	11.154	85,49 %	especies con más pool
Ronda 2 de minería (tras purga)	4.688	89,87 %	ídem
Todo purgado	76.585	82,34 %	la subida sobre 81,18 % es sobre todo composición
Panel por reino (78.180 filas, sin purga por observador): marino	65.813	80,54 %	el reino es metadato, no filtra la publicación
terrestre	9.853	93,30 %	
aves	2.027	92,25 %	
foráneas (lessepsianas, etc.)	487	82,34 %	n pequeño

Sobre las 76.585 filas purgadas, por reino: marino 80,37 %, terrestre 93,37 %, aves 92,22 %, foráneas 82,08 %.

AutoID en la práctica. En 493 publicaciones históricas auditadas el 2026-09-29 la precisión fue **96,6 %**, por banda de confianza calibrada: 0,83–0,85 → 85,2 % (n=27), 0,85–0,90 → 93,2 % (n=59), 0,90–0,95 → 95,5 % (n=155), ≥ 0,95 → 99,2 % (n=252). Una repetición sobre 726 publicaciones dio 94,6 % de acierto top-1 y 97,96 % de precisión con p ≥ 0,83 (n=589). Las fotos que AutoID no publica no son errores: en la última hora medida, de 1.429 observaciones candidatas 1.373 quedaron por debajo del umbral, 50 se omitieron porque el mismo observador ya tenía ese taxón en un álbum ese día y 81 no pasaron la puerta de calidad de foto.

Dónde están los errores. Peores especies del panel (todas con ≥ 11 fotos de evaluación): *Treptacantha nodicaulis* 0/20 (confundida con *Gongolaria barbata*), *Turbonilla pusilla* 0/18 (con *T. lactea*), *Pegusa nasuta* 0/18 (con *Solea solea*), *Forskalia tholoides* 0/13 (con *F. edwardsii*), *Arion rufus* 0/29 (con *A. ater*), *Phyllidiella granulata* 0/16 (con *Phyllidiopsis krempfi*), *Carduelis carduelis* 35 % de 40 (con *Spinus spinus*). Confusiones más frecuentes (errores): *Petalifera petalifera* $\rightarrow$ *P. ramosa* 31, *Patella aspera* $\rightarrow$ *P. ulyssiponensis* 27, *Tamarix africana* $\rightarrow$ *T. gallica* 26, *Elysia marginata* $\rightarrow$ *E. ornata* 24, *Pyracantha coccinea* $\rightarrow$ *P. crenulata* 24, *Dictyota implexa* $\rightarrow$ *D. dichotoma* 23, *Ulva rigida* $\rightarrow$ *U. lactuca* 22, *Diplodus sargus* $\rightarrow$ *D. cadenati* 21. La mayoría son pares congenéricos de morfología muy parecida; este informe no analiza por qué falla cada par.

Lo que estas cifras no dicen. Son de conjunto cerrado y correladas por observador; el KPI operativo es la reacción posterior de terceros a lo publicado, que para los rescates por recorte aún no existe. En este informe no se desglosó el acierto por especie según el tamaño de su galería.

Acierto útil con abstención jerárquica (2026-10-03, offline, probabilidades calibradas). Sobre las mismas 78.180 filas de campo, con las probabilidades calibradas de los tres niveles (especie, género, familia; calibración ajustada sobre estas filas, por tanto algo optimista), una cascada «publicar especie si $p \geq 0,83$; si no, género si $p_{\text{género}} \geq \tau$; si no, familia si $p_{\text{familia}} \geq \tau$ » da:

Política	Fotos con ID publicable	Precisión de ese conjunto
Solo especie, $p \geq 0,83$	65,1 %	95,9 %
+ género, $\tau = 0,83$	77,2 % (+12,1 pp)	95,6 % (añadidas: 93,7 %)
+ género, $\tau = 0,90$	74,1 % (+9,0 pp)	95,9 %
+ género 0,83 + familia 0,83	83,8 % (+18,7 pp)	95,3 % (familia añadida: 91,7 %)
+ género 0,90 + familia 0,90	79,9 % (+14,8 pp)	95,9 %

Publicar a nivel de familia solo compensa con $\tau \geq 0,90$; con 0,83 su precisión baja al 91,7 %. El acierto top-1 de especie (82,46 % del panel, 77,5 % en Tier 1) no cambia por construcción: la ganancia está en fotos que reciben una identificación correcta en el rango más grueso que el modelo puede defender. Las publicaciones reales de AutoID por recorte y por género son aún pocas y casi sin revisión de terceros para validar estas cifras. **Comprobación fuera de muestra (2026-10-03):** sobre 575 observaciones recientes de Minka de grado investigación no usadas en la calibración (excluidas las fugas con similitud top-1 $\geq 0,98$), p de especie $\geq 0,83$ cubrió el 73,2 % de las fotos con una precisión del 91,7 % (4 pp por debajo del 95,9 % en muestra), y el paso a género añadió +7,3 pp de fotos con 85,7 % de precisión ($p_{\text{género}} \geq 0,83$), +4,3 pp con 88,0 % ($\geq 0,90$) y +2,4 pp con 92,9 % ($\geq 0,95$). La tabla en muestra es por tanto optimista; solo la regla $p_{\text{género}} \geq 0,95$ alcanza la precisión de especie fuera de muestra. Una segunda muestra independiente (692 observaciones más) dio la misma imagen; conjuntamente ($n = 1.267$): p de especie $\geq 0,83$ cubre el 71,1 % con 91,2 % de precisión, y el paso a género añade +7,4 pp con 88,3 % ($\geq 0,83$), +4,4 pp con 87,5 % ($\geq 0,90$) y +2,4 pp con 90,3 % ($\geq 0,95$; $n = 31$ fotos añadidas), de modo que la ganancia de la abstención jerárquica es real pero pequeña ($\approx +2$ a $+7$ pp de fotos) y algo menos precisa que publicar a nivel de especie.

5.2 Trabajos relacionados y líneas base

Posición. BioFauna se sitúa entre dos líneas de trabajo. Los modelos visión-lenguaje preentrenados sobre el árbol de la vida (BioCLIP [1], construido sobre CLIP [4]) dan embeddings que separan especies sin entrenamiento específico; los grandes corpus de ciencia ciudadana (iNaturalist [5]) aportan las fotografías etiquetadas. Muchos sistemas desplegados ajustan un clasificador con esos datos; BioFauna, en cambio, mantiene el codificador congelado y hace **recuperación k-NN sobre una galería regional** con abstención calibrada, de modo que añadir o corregir una especie es editar la galería, no reentrenar. Las pérdidas de aprendizaje métrico (triplet [13], FaceNet [12], contrastiva supervisada [6]) y el ajuste fino eficiente

(LoRA [3], QLoRA [2]) eran las alternativas obvias; el §4.2 recoge que ninguna superó a la recuperación congelada sobre esta galería.

Líneas base de este informe. (a) *Centroide más cercano* sobre los prototipos publicados (demo pública): **74,73 %** top-1 sobre las 78.180 filas de campo (2026-10-03). (b) *k-NN simple con voto mayoritario* (k = 15, búsqueda exacta sobre el índice de producción), sin el agregador con temperatura, el tope por clase, el prior geográfico ni la calibración: **79,86 %** (1-NN simple: 79,10 %), frente a 82,46 % del sistema completo de producción sobre las mismas filas; es decir, la capa de decisión suma unos 2,6 pp sobre el voto simple y la recuperación en sí unos 5,1 pp sobre un clasificador solo de prototipos. (c) *Cabezas ajustadas o de aprendizaje métrico*: puntuadas en el §4.2 sobre conjuntos de evaluación anteriores, descartadas. (d) *La sugerencia de visión por computador de iNaturalist*, como línea base de AutoID: medida **parcialmente** el 2026-10-03 (n = 98 fotos de campo; la ejecución se detuvo por un límite HTTP 429 antes de las 300 previstas y no se reintentó): iNaturalist CV da **55,1 %** de acierto top-1 en especie y **67,3 %** en género, frente a **84,7 %** de BioFauna sobre las mismas fotos (BioFauna acierta y iNaturalist no: 31; al revés: 2). Con n = 98 el intervalo es amplio (unos ±8 pp), por lo que es orientativo, no una cifra principal; falta completar a n = 300.

Línea base	Evaluación (filas)	Acierto especie	Estado
BioFauna completo (producción, panel 5-oct)	78.180	82,46 %	medida
Centroide más cercano (prototipos publicados)	78.180 (2026-10-03)	74,73 %	medida
k-NN simple, voto mayoritario (k = 15)	mismas filas	79,86 % (1-NN: 79,10 %)	medida
BioFauna vigente (panel tras all08it2)	78.145	83,14 %	medida (stats.json 0,8314)
Sugerencia CV de iNaturalist	98 (parcial; objetivo 300)	55,1 % (BF 84,7 % en las mismas)	parcial

La capa de decisión suma ≈2,6 pp sobre el voto k-NN simple y la recuperación ≈5,1 pp sobre solo prototipos (medido el 2026-10-03 sobre 78.180 filas). La línea base iNat sigue incompleta (n = 98 por HTTP 429).

5.3 Evaluación limpia, promociones del índice y métodos no adoptados

Conjunto de evaluación. El panel de campo (78.145 filas, acierto de especie 82,463 % el 2026-10-05) contenía fotos duplicadas (12.416 filas), fotos con varios sujetos (2.933) y filas cuya propia foto estaba en la galería. La evaluación *limpia* v2 (62.796 filas) da 82,841 % (Tier 1 77,93 %). Una auditoría de fuga completa deja **54.878 filas sin fuga (índice vivo 80,63 %, Tier 1 76,42 %)**; todo candidato se informa también sobre las filas sin fuga (umbrales 0,95 y 0,995).

Promociones a producción (cada una con copia previa y script de marcha atrás; McNemar sobre filas emparejadas y guardia por especie: ninguna con n≥10 pierde ≥3 fotos ni >30 puntos).

Fecha	Cambio	Panel (78.145)	Sin fuga	Arreglos / roturas	Guardia
2026-10-05 18:45	<i>Combo limpio</i> : tanda de reembed de 58 especies + bloque E + cosecha pequeña, sin 4 especies de guardia y sin los vectores responsables de 3 especies «ladronas»	82,463 → 82,626 % (+0,163 pp, p=2e-11)	+0,261 pp (≥0,95) / +0,212 pp (≥0,995)	240 / 113 (panel); 212 / 69 y 213 / 81 (sin fuga)	limpia
2026-10-06 02:50	<i>Lotes de cosecha 01+02</i> (71 especies, fotos añadidas de iNat, ladronas retiradas iterativamente)	82,626 → 82,85 % (+0,223 pp, p=7e-27)	+0,503 pp (≥0,95) / +0,424 pp (≥0,995)	217 / 43	limpia

Índice tras ambas: 4.543 especies, 1.132.767 vectores, alineado. Los lotes de cosecha medidos contra la base nueva dan rendimientos decrecientes (lote 03: +0,088 pp; lote 04: +0,024 pp): cada especie aporta solo 8–44 fotos nuevas aceptadas porque el límite es el número de observaciones research grade no vistas, no los filtros. **Efecto hermana:** añadir fotos a una especie baja el acierto de sus parientes cercanos (p. ej. *Pyreanthra coccinea* → *P. crenulata* 32 → 19 de 40), de modo que los lotes se combinan y se retiran iterativamente las especies «ladronas» hasta que la guardia queda limpia.

Hallazgo sobre la cobertura de la galería. A 2026-10-06 los discos contienen 1.223.506 fotos (SSD + archive) pero el índice tiene 1.132.767 vectores: **96.392 fotos de 867 especies nunca se embebieron** (fotos cosechadas después del último embed de cada especie; p. ej. *Papaver rhoeas* 33 vectores frente a 1.000 fotos). Está en curso el reembed completo por especie de las 715 que siguen por debajo del 100 % (72.298 fotos, 3.845 errores del panel), con los mismos filtros de fuga (similitud de embedding $\geq 0,98$ con la galería, $\geq 0,95$ con cualquier foto de evaluación y toda su observación, comprobaciones de centroide y de prototipo propio).

Acierto según el tamaño de la galería (panel limpio, 62.248 filas): 0–25 fotos 68,6 %; 25–50 76,0 %; 50–100 65,7 %; 100–200 82,0 %; 200–500 82,2 %; 500–1.000 86,1 %; ≥ 1.000 89,2 %.

Resultados nulos o negativos (no adoptados).

Idea	Resultado
Quitar vectores de prototipo discordantes (1.188)	−0,023 pp (25 arreglos / 43 roturas, $p=0,039$ en contra; 32 especies empeoran)
DINOv3 como desempate en 16 pares confundibles	58,9 % frente a 59,6 % de BioFauna; desempate nulo en todos los δ
Comparador visión-lenguaje (MiniCPM-V)	51,9 % frente a 58,3 % de BioFauna (108/579 respuestas válidas)
Grounding DINO y YOLO26n afinado para el recorte de atención	Peores que la fusión actual (GDINO 74,0 frente a 80,85 % en 4.000 fotos; YOLO + mejor = idéntico, 14/14)
Filtro de subexposición en las fotos que la foto entera no publica	Publicarían 17 de 392; 15 aciertos y 2 errores (88,2 %); casi todas ya cubiertas por el rescate de atención
Color (histogramas Lab, paleta k-means) como desempate	Neto negativo en todo δ ; en las publicadas arregla 0 y rompe 4–13
Prior de zona (conteos locales de especies) como desempate	El argmax simple pierde; con condición $\geq 10\times$ da +3/−0 en la muestra de terceros (demasiado pequeña para concluir)
Reembed de Posidonia/fanerógamas; cosecha local de galerías pequeñas	+0,005 pp (3/0); +0,008 pp

Cambios en la identificación automática (AutoID). La regla de «evitar observaciones hermanas del mismo usuario y día» se retiró el 2026-10-04: sobre 349 observaciones publicadas, las 42 (12 %) sustituidas por una alternativa acertaron 3 de 11 juzgadas (27 %) frente a 102 de 105 (97 %) de las no sustituidas; además, la similitud cruda de la alternativa se comparaba con el mínimo como si fuera una probabilidad calibrada (causa de una identificación errónea real). Un replay de 14 días (500 publicaciones) de la cascada actual (foto entera; si no, corrección de dominante azul; si no, recorte de atención con guardia estricta) da 97 % de acierto (77/79 juzgadas) donde publica la misma especie, y corrige 4 de 7 cambios juzgados rompiendo 2. El umbral de especie sigue en 0,83; la publicación a nivel de género con $p\geq 0,95$ está activa; la publicación por mezcla de recortes está en pausa.

Límites de estas cifras. Las observaciones juzgadas son las que tienen identificación de otro usuario; los replays usan el modelo de hoy, no el de la fecha de publicación; las ganancias de la cosecha se miden sobre un panel construido con las mismas fuentes que la galería, así que las filas sin fuga son la estimación más fiable.

5.4 Cifras vigentes tras el promote all08it2 (OOS 83,14 %)

Panel vigente (dataset/stats.json, regenerado tras el promote; calibration.created=2026-10-08T23:38:07):

Magnitud	Valor	Fuente
Filas del eval	78.145	stats.json → calibration.n_samples; calib_raw_t05_meta.json
Acierto especie OOS	83,14 % (0,8314)	stats.json overall_accuracy / calibration.field_acc.species
Género	87,9 % (0,8793)	stats.json calibration.field_acc.genus
Familia	91,0 % (0,9102)	stats.json calibration.field_acc.family
Índice live (health)	1.198.265 vectores / 4.543 spp	stats.json live_health (tras all08it2; mensaje Robotin 8-oct 23:42)

Serie del panel (78.145 filas):

Hito	OOS especie	Fuente
Pre-combo limpio (5-oct)	82,463 %	§5.3
Tras <i>combo limpio</i>	82,626 % (+0,163 pp)	§5.3
Tras lotes de cosecha 01+02	82,85 % (+0,223 pp)	§5.3
Tras <i>all08it2</i> (8-oct 23:42)	83,14 %	stats.json; confirmación agent-bus/inbox/claude/20261008-234238-robotin.md (antes 0,8285)

El staging midió delta **+0,294 pp** (fix 353 / break 123, p=0; criterio *b* de especies 163/91 no cumplía 2×; Robotin promocionó igualmente: artifacts/decide_promote_calib_raw_t05_stg_all08it2_20261005.json).

AutoID (umbral de especie 0,83). En el eval completo, con el calibrador logístico vigente (calibration.json coef/mu/sd sobre features del k-NN en calib_raw_t05.jsonl):

Umbral	Cobertura	Precisión	n
p ≥ 0,83 (eval completo)	66,42 % (≈ 66,5 %)	95,97 % (≈ 96 %)	51.906 / 78.145
p ≥ 0,80 (operating_points, split test)	69,9 %	95,4 %	16.409
p ≥ 0,85 (operating_points, split test)	65,3 %	96,2 %	15.326

La tabla operating_points del calibrador **no** incluye exactamente 0,83 (salta de 0,80 a 0,85); el punto 0,83 del eval completo es el que usa producción. Precisión real de publicaciones históricas auditadas: **96,6 %** (n=493; stats.json kpi_referencia.autoid_real).

Métodos descartados (cifras medidas; no adoptados). Complementa §4.2 y §5.3:

Método	Resultado	Fuente
SigLIP (2.º backbone, desempate top-5)	27 arreglos / 36 roturas, n=12.298, p=0,31 (neto negativo)	artifacts/exp_altbackbone_siglip_20260930.json
DINOv2 (fusión; scripts mal llamados DINOv3)	−6,75 pp vs producción	§4.2 R22
DINOv3 como desempate (16)	58,9 % frente a 59,6 % de BioFauna;	artifacts/exp_dinov3_pares_20261005.json; §5.3

Método	Resultado	Fuente
pares)	desempate nulo en todos los δ	
VLM (MiniCPM-V)	51,9 % frente a 58,3 % BF (108/579 respuestas válidas)	artifacts/exp_vlm_compara_pares_20261005_minicpm-v_latest.json; §5.3
BioCLIP-2 ViT-L (2.º backbone)	+0,40 pp en las filas tocadas (+0,064 pp sobre el eval), $p=0,06$	artifacts/exp_altbackbone_bioclip2_20260930.json; experimentos/EXPERIMENTOS_HACIA_100_20260930.md E9
YOLO crop (YOLO26n vs fusión actual)	74,97 % frente a 80,85 % ($n=4.000$)	artifacts/exp_det_ab_20261005_yolo.json; §5.3
ArcFace / LoRA	R4 empate con k-NN; R5 +0,0 pp OOS (100 spp); R6 -31,2 pp (1.358 spp)	§4.2 R4–R6
Poda de outliers de embedding	-0,21 a -1,45 pp	§4.2 R10
Limpieza de prototipos discordantes	-0,023 pp	§5.3

Figuras generadas (matplotlib, 2026-10-09): figures/fig_serie_oos_promotes.png, fig_acc_especie_genero_familia.png, fig_autoid_precision_cobertura.png, fig_metodos_descartados.png (fuentes en figures/fuentes_cifras_20261009.json).

6. Limitaciones

1. El top-1 de especie no es nivel experto en invertebrados crípticos; las especies con poca galería o evaluación fina son mucho más difíciles que la media del panel.
2. No hay estudio de generalización fuera del Mediterráneo.
3. El código público es un **identificador de reconstrucción** (prototipos + k-NN local opcional), no el volcado del servicio de producción en HanSolo.
4. El panel de campo vigente da **83,14 %** de acierto de especie (78.145 filas; dataset/stats.json); una fracción de filas puede seguir correlacionada con la galería, y el KPI operativo sobre observaciones recientes suele ser más bajo que el panel cerrado.
5. Las correcciones de curadores aún no cierran un bucle de entrenamiento automático.
6. **Recuperación de conjunto cerrado:** las especies ausentes del catálogo reciben una respuesta errónea con confianza; mitigado en aves con guarda zero-shot, no aún en todos los grupos.
7. La precisión/cobertura de AutoID al umbral 0,83 ($\approx 96\%$ / $\approx 66,5\%$ en el eval completo) es del calibrador vigente; la precisión real de los rescates por recorte publicados sigue pendiente de reacciones de terceros.
8. La línea base de iNaturalist CV está medida solo en $n = 98$ (HTTP 429); falta completar a $n = 300$.
9. Varias ideas de mejora (SigLIP, DINOv2/v3, VLM, YOLO crop, ArcFace/LoRA, poda de outliers) se midieron y **no** se adoptaron (§5.3–5.4); el margen sobre k-NN simple (79,86 %) y centroides (74,73 %) es real pero modesto.

7. Reproducibilidad

```
git clone https://github.com/yespi/biofauna.git && cd biofauna
pip install -r requirements.txt
python -m uvicorn src.identify_service:app --host 0.0.0.0 --port 8090
```

Descarga BioCLIP-2.5 de Hugging Face al primer arranque. Usa prototipos en data/patterns/. Para reconstruir la galería completa: bajar fotos con los IDs de dataset/catalog.json, scripts/reembed_vith.py, dejar embeddings.npy junto a cada prototipo.

Licencia MIT para código y JSON/prototipos publicados. El copyright de las fotos sigue en observadores y plataformas.

8. Cómo identifica BioFauna una especie

 Pipeline: de la fotografía a una respuesta calibrada y con guardas

BioFauna es un clasificador por **recuperación**, no una red entrenada de extremo a extremo:

1. **Encoder congelado.** Cada foto de la galería se embebe con **BioCLIP-2.5 ViT-H/14** (congelado). La consulta se embebe igual: vector global **más fusión ROI al 65 %** (recorte centrado en el sujeto), normalizado L2.
2. **Búsqueda aproximada.** Un índice **FAISS** guarda los vectores de galería (hoy **≈1,20 M vectores / 4.543 especies**, alineados fila a especie).
3. **k-NN con agregador temperado.** Los $k=15$ vecinos votan con pesos $\exp(\text{similitud} / T)$, $T=0,05$, **tope de 3 votos por especie**.
4. **Correcciones de contexto.** Prior **geográfico** y manejo de **pares crípticos** corrigen el ranking cuando dos especies son casi idénticas a la vista.
5. **Calibración jerárquica.** Un modelo logístico por especie convierte la puntuación k-NN en **probabilidad calibrada**, con respaldo a género/familia; bajo el umbral el servicio **se abstiene**.
6. **Rescate zero-shot (2026).** Si la similitud top-1 es baja ($< 0,85$), se consulta un zero-shot a todo el catálogo (2.985 etiquetas); si coincide con *otra* especie a $p \geq 0,90$, gana. Efecto medido: **+0,91 pp** en la evaluación de campo.
7. **Guardas de publicación (AutoID).** No se publica a especie si el **margen** top-1/top-2 es $< 0,02$, si la observación queda fuera de dominio o hay desacuerdo vocal; una **guarda de curadores** retira identificaciones cuando un curador corrige a nivel de clase o superior.

9. Cómo ha mejorado el modelo, paso a paso




etapa	cambio	efecto
YOLOFauna (2024–2026)	BioCLIP ViT-L + k-NN	63.9 %
Aug 2026	full re-embedding with BioCLIP-2.5 ViT-H/14	70.6 %
Aug 2026	k=15 + hierarchical fallback + calibration hygiene	71.7 %

etapa	cambio	efecto
Aug 2026	hierarchical calibration (species/genus/family)	74.1 %
Sep 2026	3-vote cap per species, ROI fusion, geographic prior	77.9 %
Sep 2026	evaluation leak fixed → honest panel (near-100 % of the drop was leakage, not error)	79.4 %
Sep 2026	gallery hygiene : 135 duplicate synonym slugs merged (Minka authority), ~1,000 mislabelled photos relocated, 57 quarantined	79.6 %
Sep 2026	zero-shot rescue + publication guards	79.6 % (+0.91 pp on the same rows; the headline moves with the evaluation)

Dos lecciones que marcaron el proyecto: (a) **la evaluación forma parte del modelo** — an unfixed leak in the evaluation made the system look better than it was; (b) **la calidad de la galería gana a la complejidad del modelo** — synonyms, contamination and mislabelled observations cost more accuracy than any hyper-parameter we tuned (LoRA/QLoRA/ triplet/ArcFace/SupCon on this embedding space were all rejected by measurement).

10. Datos, evaluación y operación



- **Fuentes** (imágenes públicas): **Minka SDG** 377,476 · **iNaturalist** 779,411 · GBIF 39,570 · Wikimedia Commons 6,677 · DORIS/FFESSM 5,091 · SeaSlugForum 3,147 · WoRMS 1,320 · FishBase 1,072 → **≈1.22 M photographs**.
- **Una copia de cada foto**, nunca se borra; cada reubicación lleva manifiesto y script de marcha atrás.
- **Evaluación de campo**: solo fotos de campo (iNaturalist/Minka research grade), 20–30 por especie, auditadas contra fugas antes de fusionar.
- **Todo cambio de producción se mide** (McNemar + guardia por especie); el índice anterior queda como **marcha atrás 24 h**.
- **QA continuo**: contaminación de galería (diaria), auditoría de fuga del eval minado (semanal, con purga) y alineación índice ↔ catálogo (cada 10 min).

Agradecimientos

Xavier Salvador, Miquel Pontes y Manuel Ballesteros (GROC/OPK). Comunidades Minka e iNaturalist. WoRMS. BioCLIP (Stevens et al.).

Disponibilidad de datos

Código, prototipos, catálogo, calibradores, priors, pares crípticos: este repositorio. Backbone: Hugging Face imageomics/bioclclip-2.5-vith14. Imágenes: Minka/iNaturalist/GBIF por separado.

Referencias

Las mismas que la versión inglesa (01_biofauna.md).

Manuscrito orientado a Biodiversity Data Journal / PeerJ. Artefactos y cifras en este repositorio.
